# Etapa 2: Critérios de Inclusão e Exclusão dos Dados

Disciplina: Big Data e Analytics, UCSAL 2026.2
Alunos: Caio Oliveira Sampaio e Victor Oliveira Santana Silva
Tema: Diversidade na Tecnologia: Raça, Gênero e o Funil de Liderança no Setor de TI Brasileiro
Bases: RAIS 2025 e Novo CAGED 2025 (PDET / Ministério do Trabalho e Emprego)

## 1. Critérios de inclusão

Pra um registro entrar no estudo, ele precisa passar por três coisas: ser de uma empresa de TI, ser de 2025, e ser do tipo que a gente está contando.

### Setor de atividade

Toda empresa tem um código que diz o ramo dela, o CNAE. As de tecnologia são as que começam com 62 ou 63: o 62 é serviço de TI mesmo, e o 63 é serviço de informação. Dá 10 códigos no total:

| Subclasse | Atividade |
|---|---|
| 6201501 | Desenvolvimento de programas sob encomenda |
| 6201502 | Web design |
| 6202300 | Desenvolvimento e licenciamento de programas customizáveis |
| 6203100 | Desenvolvimento e licenciamento de programas não customizáveis |
| 6204000 | Consultoria em tecnologia da informação |
| 6209100 | Suporte técnico, manutenção e outros serviços de TI |
| 6311900 | Tratamento de dados, provedores de aplicação e hospedagem |
| 6319400 | Portais, provedores de conteúdo e outros serviços na internet |
| 6391700 | Agências de notícias |
| 6399200 | Outras atividades de serviços de informação |

Esse código olha a empresa, não a pessoa. Quem trabalha com TI dentro de um banco fica de fora, e a recepcionista de uma empresa de software fica dentro. A gente sabe que é uma limitação, mas usamos assim porque é o jeito que os estudos de mercado de trabalho delimitam o setor.

### Período

Ano de 2025 na RAIS e os doze meses de 2025 no CAGED. É o ano mais novo que existe publicado nas duas, e pegar o mesmo período deixa a gente comparar uma coisa com a outra.

### Unidade de observação

Na RAIS, cada linha que a gente conta é um emprego que estava ativo em 31 de dezembro. No CAGED, cada linha é uma contratação ou uma demissão. São contagens diferentes, já que a RAIS diz quem está empregado e o CAGED diz quem entrou e saiu.

## 2. Critérios de exclusão

Depois do filtro de TI sobraram 1.150.682 registros na RAIS e 609.952 no CAGED. Daí a gente foi cortando o que não servia, nesta ordem:

### RAIS

| Critério de exclusão | Excluídos | Restam |
|---|---|---|
| Vínculo encerrado antes de 31 de dezembro | 336.367 | 814.315 |
| Remuneração ausente ou igual a zero | 42.177 | 772.138 |
| Jornada fora do intervalo de 1 a 44 horas | 63.363 | 708.775 |
| Campo obrigatório ausente | 8 | 708.767 |
| Registro duplicado | 12.180 | 696.587 |
| Total excluído | 454.095 (39,5%) | 696.587 |

A RAIS guarda todo emprego que existiu no ano, e a gente quer saber quem estava empregado em dezembro. Quem foi contratado em março e saiu em agosto não estava lá no fim do ano. Se deixasse entrar, a mesma vaga seria contada duas vezes quando outra pessoa assumisse ela.

Salário zero costuma ser gente afastada o ano todo ou de licença sem receber. Se ficasse, puxaria a média pra baixo sem ser salário de verdade.

Jornada acima de 44 horas não bate com a lei, e jornada zero é campo que ficou em branco. Possivelmente os dois são erro de quem preencheu essa declaração.

Campo obrigatório que faltou são os registros sem sexo, raça/cor, cidade ou profissão.

### Novo CAGED

| Critério de exclusão | Excluídos | Restam |
|---|---|---|
| Movimentação sem saldo +1 ou -1 | 0 | 609.952 |
| Campo obrigatório ausente | 529 | 609.423 |
| Total excluído | 529 (0,1%) | 609.423 |

O CAGED quase não perdeu nada porque já chega validado pelo eSocial. Os 529 que saíram tinham código de profissão que não existe na tabela oficial.

**Colunas descartadas**

A gente também jogou coluna fora, onde a RAIS vem com 62 colunas e usamos 12. O CAGED vem com 28 e também usamos 12.

E o mais importante é a privacidade, onde removemos o bairro e distrito. A versão pública já vem sem nome e sem CPF, mas bairro junto com profissão e faixa de salário daria pra chegar perto de identificar alguém, então removemos isso.

O resto sai por ser repetido ou por não ter a ver com a pergunta. Repetido, por exemplo, seria a faixa de salário em salários mínimos, já que temos o valor em reais. E causa de afastamento, nacionalidade, natureza jurídica, tipo de deficiência, ano de chegada ao Brasil e o salário mês a mês são dados bons, porém não falam nada sobre quem chega à chefia.

**Supressão por tamanho de célula**
Tem um último corte, que acontece na hora de mostrar. As tabelas públicas escondem qualquer combinação com menos de 5 pessoas. Se alguém filtrar um estado, uma raça e um cargo de chefia ao mesmo tempo, o número pode acabar apontando pra uma pessoa só.

## 3. O que decidimos não excluir

**Quem não declarou raça ou sexo**
Continuam na base, com sua própria categoria. Num trabalho sobre desigualdade racial, não ter declarado já diz alguma coisa, e isso não acontece por acaso entre os grupos. Se a gente jogasse fora, o percentual de todo mundo poderia mudar.

**Ocupação fora da CBO 2002**
O funil usa o primeiro número do código da profissão: 1 é chefia, 2 é profissional e o resto é base. Só que um código inválido tipo 999999 começa com 9 e cairia na base, inchando justo o número que a gente quer medir, então ao invés de apagar ou classificar errado, criamos o nível "Não classificado", que fica guardado mas fora da conta do funil.

**Vínculos de aprendiz e tempo parcial**
Ficam, porque trabalhar menos horas também é uma condição de trabalho normal, e tirar isso pode bagunçar a base da pirâmide, que é bem onde eles estão.

## 4. Como os critérios afetam a leitura dos resultados

A maior limitação é que isso aqui só enxerga carteira assinada. Quem trabalha como PJ, informal ou autônomo não aparece, e em tecnologia isso é bem comum. Então o resultado vale pro mercado formal, e não pro setor como um todo.

O corte de 31 de dezembro também puxa pro emprego mais estável. Quem ficou pouco tempo tem menos chance de aparecer na foto, e isso pode esconder a rotatividade dos grupos que mais trocam de emprego. É por isso que mantivemos o CAGED, que mede exatamente essa movimentação e não passa por esse corte.